

PROJET DE FIN D'ÉTUDES

Architecture Cloud-Native de la Couche d'Exécution

Rapport technique — Workers conteneurisés Node.js + Puppeteer
pour l'automatisation LinkedIn à grande échelle

Projet : LinkedIn Agent — Prospection B2B intelligente

Auteur : [Votre Nom]

Date : Mai 2026

Contexte : Soutenance de fin de projet

Table des matières

- 1. Introduction et contexte
- 2. Architecture actuelle et ses limites
- 3. La solution proposée : Workers Conteneurisés
- 4. Comment ça marche en détail
- 5. Technologies utilisées et justifications
- 6. Implémentation dans le projet
- 7. Bénéfices concrets et métriques
- 8. Sécurité et résilience
- 9. Déploiement et scalabilité
- 10. Conclusion

1. Introduction et contexte

Le **LinkedIn Agent** est une application full-stack qui automatise la prospection B2B sur LinkedIn. Elle combine quatre couches technologiques :

- **Dashboard Next.js** — Interface de gestion des campagnes, prospects et messages
- **Agent IA (OpenAI)** — Génération d'actions personnalisées via LLM
- **Extension Chrome** — Exécution des actions directement dans le navigateur de l'utilisateur
- **Base de données PostgreSQL (Neon)** — Persistance de toutes les données métier


Le problème identifié

Lors de la conception initiale, l'exécution des actions LinkedIn (envoyer une demande de connexion, envoyer un message, visiter un profil) était déléguée à une **extension Chrome** installée sur le poste de l'utilisateur. Cette approche, bien que fonctionnelle pour un MVP (Minimum Viable Product), présente des limitations critiques dès qu'on cherche à passer à l'échelle.

Question centrale de ce rapport : Comment déporter l'exécution des actions LinkedIn du navigateur de l'utilisateur vers une infrastructure cloud, *sans ajouter de complexité inutile*, et en réutilisant au maximum les technologies déjà présentes dans le projet ?

2. Architecture actuelle et ses limites

2.1 Schéma de l'architecture existante



2.2 Fonctionnement détaillé

1. L'utilisateur crée une campagne dans le dashboard
2. L'agent IA génère une liste d'actions (visiter X profils, envoyer Y connexions)
3. Ces actions sont insérées dans la table `linkedin_actions_queue` avec le statut `approved`
4. L'**extension Chrome** fait du **polling** toutes les 30 secondes sur `/api/linkedin-actions?status=approved`
5. L'extension exécute l'action dans le navigateur de l'utilisateur (manipulation du DOM LinkedIn)
6. L'extension met à jour le statut via `PATCH /api/linkedin-actions`

2.3 Les cinq limites critiques

Limite	Description	Impact
Consommation mémoire	Chrome consomme 500 MB à 1 GB de RAM par instance	Ralentit significativement le PC de l'utilisateur
Sérialisation	Une seule action peut être exécutée à la fois	Une campagne de 50 actions prend plusieurs heures
Disponibilité	Si l'utilisateur ferme son PC ou son navigateur, tout s'arrête	Pas d'exécution 24/7, week-end compris
Dépendance client	Toute l'exécution dépend de l'environnement local	Instable, difficile à debugger et monitorer
Scalabilité nulle	Impossible de paralléliser ou d'ajouter des ressources	Verrou technologique pour les campagnes massives

Anecdote concrète

Si un utilisateur lance une campagne de 100 invitations de connexion un vendredi soir à 18h, puis éteint son ordinateur pour le week-end, les 90 actions restantes restent bloquées au statut `approved` jusqu'à lundi matin 9h. Cette latence de **63 heures** est inacceptable pour un outil de prospection B2B où la réactivité est un avantage compétitif.


3. La solution proposée : Workers Conteneurisés

3.1 Principe général

Au lieu de confier l'exécution à l'extension Chrome du client, nous la déportons vers des **workers conteneurisés** qui tournent sur un serveur cloud. Ces workers :

- Prennent une action dans la file d'attente PostgreSQL
- Lancent un **navigateur Chrome headless** (sans interface graphique)
- Exécutent l'action sur LinkedIn
- Mettent à jour le statut dans la base de données
- Libèrent les ressources

3.2 Architecture cible



3.3 Philosophie : réutiliser avant d'ajouter

Au lieu d'introduire Python, Celery, Redis, FastAPI ou Kubernetes — ce qui aurait doublé la complexité du projet — nous avons fait le choix de **réutiliser 100 % des technologies existantes** et d'ajouter **une seule dépendance** : Puppeteer (package npm).

Ce qu'on aurait pu ajouter (approche classique)	Ce qu'on a fait (approche minimaliste)
FastAPI (Python)	Next.js API routes (déjà dans le projet)
Celery (Python)	Script Node.js avec polling SQL
Redis (broker de messages)	PostgreSQL <code>FOR UPDATE SKIP LOCKED</code>
Playwright (Python)	Puppeteer (npm, même écosystème)
Kubernetes (orchestration)	Docker Compose (déjà dans le projet)
4 nouvelles technologies	1 package npm

Règle d'or appliquée : "Le nombre de technologies dans un projet est une dette. Moins il y en a, plus le projet est maintenable."

4. Comment ça marche en détail

4.1 Le verrouillage distribué — cœur du système

Quand plusieurs workers tirent des actions de la même file d'attente, le risque principal est de **traiter la même action deux fois** (race condition). La solution est le **verrouillage pessimiste** natif de PostgreSQL.


```
UPDATE linkedin_actions_queue
SET status = 'processing',
    claimed_by = 'worker-1',
    claimed_at = NOW()
WHERE id = (
    SELECT id FROM linkedin_actions_queue
    WHERE status = 'approved'
        AND (claimed_by IS NULL OR claimed_at < NOW() - INTERVAL '5 minutes')
    ORDER BY created_at ASC
    FOR UPDATE SKIP LOCKED -- ← Clé magique
    LIMIT 1
)
RETURNING *;
```

Explication de **FOR UPDATE SKIP LOCKED**

- **FOR UPDATE** — Verrouille la ligne sélectionnée pour le reste de la transaction
- **SKIP LOCKED** — Saute les lignes déjà verrouillées par un autre worker
- **Résultat** : Si 5 workers exécutent cette requête simultanément, chacun récupère une action différente. *Aucune duplication possible.*

4.2 Le cycle de vie d'une action

[Agent IA crée l'action]





4.3 Le Browser Pool (optimisation mémoire)

Lancer un nouveau processus Chrome à chaque action coûterait 300-500 MB. Au lieu de ça, le worker utilise un **pool de browsers** :

1. Le worker lance **un seul** browser Chrome au démarrage
2. Pour chaque action, il crée une **nouvelle page** (pas un nouveau browser)
3. Après l'action, la page se ferme mais le browser reste ouvert
4. Tous les 20 cycles, le browser redémarre pour éviter les fuites mémoire

Économie concrète : 1 browser = ~200 MB pour 20 actions, au lieu de 20×300 MB = **6 GB** si on relançait Chrome à chaque fois.

4.4 Le Heartbeat et la Recovery

Problème : Que se passe-t-il si un worker meurt en plein traitement d'une action ?

Solution :

1. Chaque worker écrit un **heartbeat** dans `worker_heartbeats` toutes les 30 secondes
2. Une boucle de **recovery** tourne en parallèle et libère les actions bloquées depuis plus de 5 minutes
3. Ces actions repassent au statut `approved` et sont reprises par un autre worker

C'est de la tolérance aux pannes sans orchestrateur externe (pas de Kubernetes nécessaire).

5. Technologies utilisées et justifications

5.1 Node.js / TypeScript

Statut : Déjà dans le projet (Next.js frontend)

Pourquoi réutiliser :

- Même langage pour le frontend, l'API et le worker → zéro friction cognitive
- Pas de nouvelle stack à sécuriser, monitorer et déployer
- Partage des types TypeScript entre les couches
- npm comme gestionnaire unique de dépendances

5.2 Puppeteer

Statut : Seule nouvelle dépendance du projet (package npm)

Pourquoi Puppeteer et pas Selenium :

- API moderne basée sur les promesses (pas de callbacks)
- Gestion automatique des waits intelligents (pas de `sleep` arbitraires)
- Headless optimisé pour les conteneurs Docker (flags `--single-process`, `--no-sandbox`)
- Même écosystème npm que le reste du projet
- Moins gourmand en mémoire que Selenium + WebDriver + Grid

Pourquoi pas Playwright : Bien qu'excellent, Playwright aurait nécessité soit l'ajout de Python au projet, soit l'utilisation de `@playwright/test` qui est plus lourd que Puppeteer pour ce cas d'usage simple. Le principe de parcimonie s'applique.

5.3 PostgreSQL comme file d'attente

Statut : Déjà dans le projet (Neon PostgreSQL)

Pourquoi pas Redis / RabbitMQ / Kafka :

- PostgreSQL est **déjà** la base de données du projet
- `FOR UPDATE SKIP LOCKED` offre un verrouillage distribué de qualité production
- Pas de nouveau service à monitorer, sécuriser, sauvegarder
- Atomicité ACID garantie pour le claim d'actions
- Pour un volume de quelques milliers d'actions/jour, PostgreSQL est amplement suffisant

"Le dogme 'il faut Redis pour les files d'attente' est un faux-ami. PostgreSQL gère nativement le verrouillage distribué avec une fiabilité ACID que Redis ne possède pas."

5.4 Docker / Docker Compose

Statut : Déjà dans le projet

Le projet avait déjà un `docker-compose.yml` avec Nginx et l'app Next.js. Nous avons simplement ajouté un service `worker`.

```
docker-compose up --scale worker=5
```

5.5 Oracle Cloud Always Free

Pourquoi Oracle et pas AWS/Azure :

Provider	Offre gratuite	RAM	Durée
Oracle Cloud	Always Free Tier	24 GB	Permanent
AWS	t2.micro	1 GB	12 mois uniquement
Azure	B1s	1 GB	12 mois uniquement

Avec 24 GB de RAM gratuites, on fait tourner 4-6 workers Chrome en parallèle. Après les 12 mois, AWS/Azure coûteraient 8-15 €/mois pour une configuration équivalente.

6. Implémentation dans le projet

6.1 Arborescence des fichiers créés

linkedin-agent-worker/	← NOUVEAU DOSSIER
├─ src/	
│ ├─ index.ts	# Boucle principale du worker
│ ├─ queue.ts	# Polling PostgreSQL + verrouillage
│ ├─ browser.ts	# Puppeteer + Browser Pool
│ ├─ types.ts	# Interfaces TypeScript
│ └─ actions/	
│ ├─ connect.ts	# Envoyer une demande de connexion
│ ├─ message.ts	# Envoyer un message
│ └─ visit.ts	# Visiter + scraper un profil
├─ Dockerfile	# Multi-stage build, Chromium Alpine
├─ package.json	# Dépendances (pg, puppeteer, dotenv)
├─ tsconfig.json	# Compilation TypeScript
└─ README.md	
db/migrations/	← NOUVEAU
├─ 001_add_worker_queue.sql	# Migration PostgreSQL
└─ README.md	
linkedin-agent-frontend/	
├─ lib/db.ts	# MODIFIÉ – fonctions worker ajoutées
└─ docker-compose.yml	# MODIFIÉ – service worker ajouté

6.2 Modification de la base de données

```
-- Colonnes ajoutées à linkedin_actions_queue
ALTER TABLE linkedin_actions_queue
ADD COLUMN claimed_by VARCHAR(255),    -- ID du worker qui a verrouillé
ADD COLUMN claimed_at TIMESTAMP;      -- Timestamp du verrou

-- Index pour le polling rapide
CREATE INDEX idx_actions_pending_claimed
ON linkedin_actions_queue(status, claimed_by, claimed_at, created_at)
WHERE status = 'approved';

-- Table de monitoring
CREATE TABLE worker_heartbeats (
  worker_id VARCHAR(255) PRIMARY KEY,
  last_seen TIMESTAMP NOT NULL,
  hostname VARCHAR(255)
);
```

6.3 Dockerfile du worker

```
# Stage 1 : Build TypeScript → JavaScript
FROM node:20-alpine AS builder
RUN apk add --no-cache python3 make g++
WORKDIR /app
COPY package*.json tsconfig.json ./
RUN npm ci
COPY src/ ./src/
RUN npm run build                # Génère dist/

# Stage 2 : Runtime minimal
FROM node:20-alpine AS runner
RUN apk add --no-cache chromium nss freetype harfbuzz ca-certificates
ENV PUPPETEER_SKIP_CHROMIUM_DOWNLOAD=true
ENV PUPPETEER_EXECUTABLE_PATH=/usr/bin/chromium-browser
WORKDIR /app
COPY --from=builder /app/dist ./dist
COPY --from=builder /app/node_modules ./node_modules
CMD ["node", "dist/index.js"]
```

Taille finale de l'image : ~300 MB (alpine + chromium minimal).

6.4 Docker Compose (service worker)

```
services:
  app:                                # ← Existant (Next.js)
    ...

  worker:                             # ← NOUVEAU
    build:
      context: ./linkedin-agent-worker
      dockerfile: Dockerfile
    environment:
      - DATABASE_URL=${DATABASE_URL}
      - HEADLESS=true
    restart: unless-stopped
    deploy:
      resources:
        limits:
          cpus: "1.0"
          memory: 1G
```

Scalabilité en une commande :

```
docker-compose up -d --scale worker=4
# 4 workers = 4 actions LinkedIn simultanées, 24h/24
```

7. Bénéfices concrets et métriques

7.1 Avant / Après

Métrique	Avant (Extension Chrome)	Après (Workers Cloud)	Gain
Actions simultanées	1	4-6 (scalable à l'infini)	× 6
RAM par navigateur	500 MB – 1 GB (PC utilisateur)	200-300 MB (serveur)	-70 %
Disponibilité	Quand le PC est allumé	24h/24, 7j/7	Permanent
Temps campagne (100 actions)	~3 heures (séquentiel)	~20 minutes (parallèle)	× 9
Tolérance pannes	Aucune (crash = tout bloqué)	Recovery auto, retry	100 %
Coût mensuel	0 € (mais limité)	0 € (Oracle Free Tier)	Équivalent

7.2 Bénéfice métier

Pour un commercial qui utilise l'agent :

- **Vendredi 18h** : Il lance une campagne de 200 connexions
- **Samedi matin** : 50 connexions sont déjà envoyées (les workers tournent la nuit)
- **Lundi 9h** : Il arrive au bureau avec 180 connexions envoyées et 12 acceptations
- **Sans les workers** : Il aurait dû laisser son PC ouvert tout le week-end

8. Sécurité et résilience

8.1 Anti-détection LinkedIn

LinkedIn détecte et bloque activement les automatisations. Le worker intègre plusieurs mécanismes de furtivité :

- **User-Agent humain** — Chrome Windows standard (pas de "HeadlessChrome" dans le UA)
- **Viewport desktop** — 1920×1080 (pas de viewport headless par défaut qui trahit l'automatisation)
- **Comportement de scroll** — Scroll aléatoire entre chaque action pour simuler la lecture
- **Délai de frappe** — Entre 30 et 80 ms entre chaque caractère (simule un humain, pas un robot)
- **Blocage des ressources** — Images, CSS, fonts bloqués → moins de trafic réseau suspect

8.2 Rate limiting

Si LinkedIn détecte un pattern trop rapide :

1. Le worker identifie le message "Vous avez atteint la limite"
2. L'action est marquée `failed` avec la raison exacte
3. Le worker passe à l'action suivante (pas de blocage infini)

8.3 Tolérance aux pannes

Scénario de panne	Comportement du système
Worker meurt en cours d'action	Action libérée après 5 min, reprise par un autre worker
Chrome crash	Browser redémarré automatiquement au cycle suivant
Réseau instable	Erreur enregistrée, retry possible via l'UI
LinkedIn change son DOM	Sélecteurs CSS extensibles (tableau de fallbacks)

9. Déploiement et scalabilité

9.1 Déploiement avec Coolify

Le projet utilise déjà **Coolify** pour le déploiement. Le worker peut être ajouté comme service Docker supplémentaire :

1. Coolify détecte le nouveau `docker-compose.yml`
2. Il build l'image du worker et la déploie
3. Il gère le SSL, le reverse proxy, les healthchecks
4. Le nombre de replicas est configurable dans l'interface Coolify

9.2 Déploiement sur Oracle Cloud (Always Free)

1. Créer une VM ARM : **4 OCPU + 24 GB RAM** (gratuit permanent)
2. Installer Docker : `sudo apt install docker.io docker-compose-plugin`
3. Cloner le repo et lancer : `docker-compose up --scale worker=4`
4. Pointer le domaine vers l'IP de la VM
5. SSL gratuit avec Let's Encrypt

Résultat : 4 workers en parallèle, 24h/24, pour **0 €/mois**.

9.3 Scalabilité future

Si le besoin dépasse 4 workers :

- Passer à Docker Swarm (natif dans Docker, pas de Kubernetes nécessaire)
- Ajouter une deuxième VM Oracle Free (4 CPU + 24 GB supplémentaires)
- Total possible gratuitement : **8 CPU + 48 GB RAM** $\approx$ 10 workers

10. Conclusion

Synthèse pour le jury

"Au lieu d'ajouter Python, Celery, Redis et Kubernetes — ce qui aurait fait passer notre projet de 1 à 3 stacks technologiques — nous avons fait le choix de l'**économie architecturale**. Le worker est un simple script TypeScript qui poll PostgreSQL et pilote Chrome via Puppeteer. Il réutilise Node.js (déjà là), PostgreSQL (déjà là), Docker (déjà là). Le seul ajout est Puppeteer, un package npm. **Résultat** : 4 actions simultanées, 24h/24, tolérance aux pannes, 0 €/mois, et une complexité divisée par 10 par rapport à une stack classique Python/Celery/Redis."

Les trois points clés à retenir

- 1 Problème résolu** : Le goulot d'étranglement de l'extension Chrome (RAM, CPU, disponibilité) est complètement éliminé.
- 2 Approche minimaliste** : Une seule nouvelle dépendance (Puppeteer) au lieu d'une nouvelle stack complète. Moins de technologies = moins de bugs.
- 3 Coût nul** : Déployable gratuitement sur Oracle Cloud Always Free avec les technologies déjà maîtrisées par l'équipe. Zéro barrière à l'entrée.

Ouverture

Cette architecture est un **pont vers le futur**. Quand le projet grandira, on pourra :

- Migrer de Docker Compose à Kubernetes (HPA autoscaling natif)
- Ajouter un vrai broker Redis si le volume dépasse 10 000 actions/jour

- Distribuer les workers sur plusieurs régions cloud

Mais pour l'instant, **la simplicité est la meilleure scalabilité.**

Annexes — Commandes utiles

```
# Lancer en développement
cd linkedin-agent-worker && npm install && npm run dev

# Lancer en production
docker-compose up --build -d

# Scaler à 4 workers
docker-compose up -d --scale worker=4

# Voir les logs
docker-compose logs -f worker

# Migrer la base de données
psql $DATABASE_URL -f db/migrations/001_add_worker_queue.sql
```

Document généré pour la soutenance du projet LinkedIn Agent — Mai 2026